

**Міністерство освіти і науки України**  
**Національний технічний університет України «Київський політехнічний**  
**інститут імені Ігоря Сікорського»**  
**Факультет інформатики та обчислювальної техніки**

**Кафедра інформатики та програмної інженерії**

**Звіт**

з лабораторної роботи № 4 з дисципліни  
«Вступ до технології Data Science»

**„РЕАЛІЗАЦІЯ ПРОЦЕСІВ ІНТЕЛЕКТУАЛЬНОГО АНАЛІЗУ ДАНИХ:  
МІНІ ПРОЕКТИ В ГАЛУЗЯХ OLAP, Data Mining, Text Mining, Voice  
Recognition”**

**Виконав(ла)**

ІІІ-12 Орищенко Я.О.  
(шифр, прізвище, ім'я, по батькові)

**Перевірів**

Писарчук О.О.  
(прізвище, ім'я, по батькові)

Київ 2023

## I. Мета роботи:

Виявити дослідити та узагальнити особливості інтелектуального аналізу даних та технологій OLAP, Data Mining, Text Mining, Voice Recognition.

## II. Завдання:

### II рівень складності 9 балів – R&D міні проект

Розробити програмний скрипт, що реалізує збір і узагальнення інформації про репертуар театральних постанов у м. Київ.

## III. Виконання:

### 3.1. Синтезована математична модель

Для створення програмного скрипту, що збирає та узагальнює інформацію про репертуар театральних постанов у місті Київ, виконаємо парсинг одного із найпопулярніших сайтів-афіш в Україні **karabas.com**.




рис. 1 – вигляд сайту karabas.com

Виконаємо парсинг за посиланням <https://kiev.karabas.com/ua/theatres/> , із вказанням параметрів дати – конкретного дня, на який шукаємо усі театральні вистави у Києві. Наприклад, для відображення вистав на 4 грудня 2023 року, посилання матиме наступний вигляд:

На початку виконання програми необхідно буде вказати початок і кінець часового інтервалу, за який нам необхідно дістати вистави. Програма ітеруватиметься по кожному дню, та додаватиме інформацію про вистави на цей день у загальний список вистав.

На сайті нас цікавить така інформація для кожної вистави: назва вистави, назва театру, дата вистави (день, місяць, рік, день тижня), час вистави, мінімальна та максимальна ціна на квитки (у разі, якщо ціна вказана не проміжком, а одним числом, то це число буде записано і у мінімальну ціну, і у максимальну). Додатково можна побачити, що у багатьох вистав у назві також в дужках дублюється назва театру, у якому ця вистава відбуватиметься – це дублювання можна видалити. Також місяць вистави варто представити у числовому форматі, що дозволить спростити майбутній аналіз даних.

### 3.2. Результати архітектурного проектування та їх опис



рис. 2 – блок-схема алгоритму програми

### 3.3. Опис структури проекту програми

Розроблений алгоритм буде реалізовано за допомогою мови програмування Python та середовища розробки PyCharm. Проект має таку структуру:




рис. 3 – структура проекту

Data Science Lab4 – каталог проекту;

main.py – файл коду програми на мові програмування Python;

data – каталог, у якому зберігаються дані, що є результатом парсину сайту.

### 3.4. Результати роботи програми відповідно до завдання

Запустимо алгоритм для пошуку театральних вистав у місті Київ на період 1 місяць: із 4 грудня 2023 року по 4 січня 2024 року. Для того, щоб задати дати, використаємо бібліотеку datetime.

```
def main():  
    start = date(year=2023, month=12, day=4)  
    end = date(year=2024, month=1, day=4)  
    df = parse_theatres_data(start, end)  
  
    print(df.head(10), '\n')  
    print(df.describe())
```

рис. 4 – головна функція програми

В результаті виконання було сформовано три файли: csv, json та excel, із даними про театральні вистави.




рис. 5 – сформовані файли із результатом парсингу

Переглянемо вміст файлу theatres.csv

| title (1)                                              | theatre (2)                                                 | day (3) | month (4) | year (5) | day_of_week (6) | time (7) | min_price (8) | max_price (9) |
|--------------------------------------------------------|-------------------------------------------------------------|---------|-----------|----------|-----------------|----------|---------------|---------------|
| title                                                  | theatre                                                     | day     | month     | year     | day_of_week     | time     | min_price     | max_price     |
| № 13                                                   | Національний академічний драматичний театр ім.Лесі Українки | 4       | 12        | 2023     | пн              | 18:00    | 80.0          | 600.0         |
| Молитва за Елвіса                                      | Національний академічний драматичний театр ім.Лесі Українки | 4       | 12        | 2023     | пн              | 18:30    |               |               |
| Кицяня                                                 | Сцена 6                                                     | 4       | 12        | 2023     | пн              | 18:30    | 300.0         | 650.0         |
| Молитва за Елвіса                                      | Національний академічний драматичний театр ім.Лесі Українки | 4       | 12        | 2023     | пн              | 19:00    | 150.0         | 150.0         |
| Естроген                                               | Театр Актор                                                 | 5       | 12        | 2023     | вт              | 18:00    | 100.0         | 350.0         |
| Генерали у спідницях                                   | Київський академічний театр "Колесо"                        | 5       | 12        | 2023     | вт              | 18:00    | 330.0         | 330.0         |
| Сім добрих справ Святого Миколая                       | Театр на Михайлівській                                      | 5       | 12        | 2023     | вт              | 18:00    |               |               |
| Дамський кравець                                       | Національний академічний драматичний театр ім.Лесі Українки | 5       | 12        | 2023     | вт              | 18:00    | 60.0          | 500.0         |
| 1984                                                   | Київський академічний драматичний театр на Подолі           | 5       | 12        | 2023     | вт              | 18:00    | 400.0         | 400.0         |
| «Мина Мазайло»                                         | МКЦ ім. І. Козловського                                     | 5       | 12        | 2023     | вт              | 18:00    | 250.0         | 250.0         |
| Що сталося в зоопарку                                  | Національний академічний драматичний театр ім.Лесі Українки | 5       | 12        | 2023     | вт              | 18:30    | 100.0         | 100.0         |
| Чорний квадрат. «Страшенно хочеться поцілувати».       | Культурний центр «Арт-Братислава»                           | 5       | 12        | 2023     | вт              | 18:30    | 250.0         | 450.0         |
| Казка про Мороза-Морозенка                             | Київський академічний театр ляльок                          | 6       | 12        | 2023     | ср              | 12:00    | 150.0         | 150.0         |
| «Інтермедія: Ангели святого Миколая». Вистава у рамках | Київський академічний театр юного глядача на Липках.        | 6       | 12        | 2023     | ср              | 13:00    | 250.0         | 250.0         |

рис. 6 – вміст файлу theatres.csv

Було сформовано документ, довжиною 546 рядків, у якому міститься інформація із назвою вистави, театром, де вистава проходить, датою, днем тижня та часом вистави, мінімальною та максимальною ціною на квитки.

Переглянемо опис числових даних, у який входить кількість даних, середнє значення, мінімальне та максимальне значення, квантили:

|       | day        | month | year   | min_price   | max_price   |
|-------|------------|-------|--------|-------------|-------------|
| count | 545.000000 | 545.0 | 545.0  | 514.000000  | 514.000000  |
| mean  | 19.548624  | 12.0  | 2023.0 | 253.832685  | 422.178988  |
| std   | 7.696562   | 0.0   | 0.0    | 144.324396  | 261.539003  |
| min   | 4.000000   | 12.0  | 2023.0 | 60.000000   | 60.000000   |
| 25%   | 14.000000  | 12.0  | 2023.0 | 150.000000  | 250.000000  |
| 50%   | 21.000000  | 12.0  | 2023.0 | 250.000000  | 400.000000  |
| 75%   | 26.000000  | 12.0  | 2023.0 | 327.500000  | 500.000000  |
| max   | 31.000000  | 12.0  | 2023.0 | 1590.000000 | 2390.000000 |

рис. 7 – опис числових даних

### 3.5. Программний код, що забезпечує отримання результату

```
from datetime import date, timedelta
from bs4 import BeautifulSoup as Bs
import pandas as pd
import requests
import json

pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)

def parse_theatres_data(start_date, end_date):
    delta = timedelta(days=1)

    results = {'title': [],
               'theatre': [],
               'day': [],
               'month': [],
               'year': [],
               'day_of_week': [],
               'time': [],
               'min_price': [],
               'max_price': []}

    months = {'січня': 1,
              'лютого': 2,
              'березня': 3,
              'квітня': 4,
              'травня': 5,
              'червня': 6,
              'липня': 7,
              'серпня': 8,
              'вересня': 9,
              'жовтня': 10,
              'листопада': 11,
              'грудня': 12}

    elements = []
    while start_date < end_date:
        today = start_date.strftime("%d.%m.%Y") # date of search in format
        dd.mm.yyyy
        start_date += delta

        response = requests.get(f'https://kiev.karabas.com/ua/theatres/{today}-
{today}/')
        soup = Bs(response.text, 'html.parser')
        if soup.find('div', class_='events-not-found'):
            break
        elements += soup.findAll('div', class_='el-row')

    for element in elements:
        info = element.find('div', class_='el-info')
        title = info.find('a', class_='el-name').text.split(' (')
        results['title'].append(title[0]) # append only title, without name of the
        theatre inside ( )
        results['theatre'].append(info.find('a', class_='el-club').text)

        date_time = info.find('p').text.split(', ')[1:] # list: [date, time]
        show_date = date_time[0].split() # list: [day, month, year]
        results['day'].append(int(show_date[0]))
        results['month'].append(months[show_date[1]]) # month name to number
        results['year'].append(int(show_date[2]))
        results['time'].append(date_time[1])
```

```

        results['day_of_week'].append(element.find('i', 'day-of-week').text)

    price_block = element.find('div', class_='el-price')
    if price_block.find('b'):
        prices = price_block.find('b').text[1:-6].split(' - ')
        results['min_price'].append(int(prices[0]))
        results['max_price'].append(int(prices[-1]))
    else:
        results['min_price'].append(None)
        results['max_price'].append(None)

# save data in csv, json, excel
dataframe = pd.DataFrame(results)
dataframe.to_csv('data/theatres.csv', index=False)
dataframe.to_json('data/theatres.json', index=False)
dataframe.to_excel('data/theatres.xlsx', index=False)
return dataframe

def main():
    start = date(2023, 12, 4)
    end = date(2024, 1, 4)
    df = parse_theatres_data(start, end)

    print(df.head(10), '\n')
    print(df.describe())

if __name__ == '__main__':
    main()

```

#### IV. Висновок:

У ході виконання лабораторної роботи, було розроблено програмний скрипт на мові програмування Python, який за допомогою бібліотеки BeautifulSoup виконує збір та узагальнення інформації про репертуар театрів у місті Київ. Було виконано парсинг сайту kagabas.com – одного із найпопулярніших сайтів-афіш України. Було зібрано дані про театральні вистави у Києві за найближчий місяць, де для кожної вистави збережено її назву, назву театру, дату, день тижня, час, мінімальну та максимальну ціну на квиток. Дані було збережено у трьох форматах: csv, json, excel.

**Виконав:**

ІІ-12 Орищенко Я.О.

**Перевірив:**

Писарчук О.О.