

ПІС Лабораторна 5

Виконав Орищенко Ярослав ІП-12

```
import requests
from selenium import webdriver
from selenium.webdriver.common.by import By
from bs4 import BeautifulSoup as BS
import spacy

titles = []
dead_russians = set()
```

Парсинг заголовків новин

BeautifulSoup

```
pages_amount = 14
url = 'https://pestrecy-rt.ru/news/tag/list/specoperaciia/page'
for page in range(pages_amount):
    r = requests.get(f'{url}/{page+1}/')
    soup = BS(r.text, 'html.parser')
    news = soup.find_all('h2', class_='oneNews__link news__bold-text')
+ soup.find_all('p', class_='oneNews__link')
    titles += [title.get_text() for title in news]
```

Selenium

```
# browser = webdriver.Chrome()
# browser.get('https://pestrecy-rt.ru/news/tag/list/specoperaciia/')

# while True:
#     for header in browser.find_elements(By.XPATH,
#     '//h2[@class="oneNews__link news__bold-text"]'):
#         titles.append(header.text)
#     for description in browser.find_elements(By.XPATH,
#     '//p[@class="oneNews__link"]'):
#         titles.append(description.text)
#     buttons = browser.find_elements(By.XPATH, '//a[@class="all-
news__button_forward"]//span[contains(text(), "Далее")]')
#     if buttons:
#         buttons[0].click()
#     else:
#         break
```

Розпізнавання імен у заголовках новин

```
nlp = spacy.load('ru_core_news_sm')
```

```

for title in titles:
    doc = nlp(title)
    names = [entity.text for entity in doc.ents if entity.label_ ==
'PER']
    dead_russians.update(names)
print(dead_russians)

{'Верховному Главнокомандующему', 'Минниханов', 'Родину', 'Елена
Корчагина', 'Жукова', 'Айгуль Сабирова', 'Валера', 'Пестрецов',
'Рустам Сафиуллин', 'Николая Чудотворца', 'Юрия Ивановича', 'Раис',
'Евгений Токмаков', 'Камиль Самигуллин', 'Рустама Минниханова',
'Эльмира Зарипова', 'Фарит Валиев', 'Артема Прокопчука', 'Алексей',
'Путин', 'Валерием Межва', 'Сергей', 'Александр Владимиров', 'Марат
Нуриев', 'Виталий Беляев', 'Валерий Максимов', 'Сергей Шойгу', 'Иван
Додосов', 'Раушании Габдрахмановны', 'Александром Агафоновым', 'Марии
Ивановны М.', 'Вячеслав Володин', 'Тамара Лаптева', 'Сергей Корчагин',
'Рустам Минниханов', 'Снегурочкой', 'Мужа', 'Гузель Удачина',
'Куюков', 'Тинчурина', 'Александра', 'Александр', 'Расиму Баксикову',
'Эдуард Вафин', 'Тимур Сулейманов', 'Ильдара Насыбуллина', 'Альберт
Ибятуллин', 'Рафката Амировича', 'Ильхама Кашапова', 'Ильхам Кашапов',
'Дедом', 'Владислав Кузнецов', 'Ивана Додосова', 'Лейла Фазлеева',
'Неустроев', 'Галина Тимофеева', 'Эдуард Шарафиев', 'Валерий', 'Алмаз
К.', 'Ринат Садыков', 'Раиса Республики Татарстан', 'Татьяна
Голикова', 'Фаниль Аглиуллин'}

```

Запис імен у файл

```

with open('dead_russians.txt', 'w') as file:
    for ork in dead_russians:
        file.write(ork + '\n')

```